PROPOSTA TÉCNICA E COMERCIAL · DOCUMENTO DE PRÉ-PITCH

Hub de IA Local para a sua Fábrica de Software

Reduza o custo com ferramentas de IA por assinatura, proteja o código dos seus clientes bancários e dê às suas três equipes uma infraestrutura própria de produtividade.

Para quem entrega software a bancos, universidades e outras instituições que exigem confidencialidade.

Material preparatório para a reunião comercial inicial · 05/10/2026

O QUE JÁ SABEMOS SOBRE O SEU MOMENTO

Vinte anos de entregas, três equipes, clientes que não perdoam falhas

Há cerca de vinte anos no mercado, a empresa atua como fábrica de software: desenvolve o sistema, entrega o código-fonte e o próprio cliente assume a manutenção depois disso. Hoje são três equipes de desenvolvimento, de cinco a seis pessoas cada, atendendo bancos, uma universidade, uma empresa de acervo e uma agência de viagens.

3	15–18	20 anos	Bancos
equipes de desenvolvimento	desenvolvedores ao todo	de mercado e de acervo técnico	entre os clientes atendidos

Há cerca de um ano, as três equipes passaram a usar ferramentas de Inteligência Artificial por assinatura para ganhar produtividade. Funcionou — mas hoje esse uso já custa cerca de **R$ 10.000 por mês**, sem um critério único de quem usa, quanto usa e para qual cliente o código está sendo processado.

Em outras palavras: a produtividade ganhou um custo real — mas ainda sem governança, sem teto e sem controle sobre para onde o código está indo.

ANTES DE FALAR DE PREÇO

O problema não é só o custo — é o que ele esconde

R$ 10.000/mês ≈ 12% do faturamento anual informado (R$ 1 milhão)

Isso já é uma linha de despesa relevante — e tende a crescer, não a se estabilizar, conforme o uso das três equipes aumenta.

Custo sem teto

Sem controle por equipe ou por projeto, o gasto pode saltar de R$10 mil para R$20–30 mil conforme o uso cresce — sem aviso prévio.

Código bancário em trânsito

Prompts e trechos de sistemas de clientes bancários e acadêmicos saem da rede da empresa a cada consulta a uma IA externa.

Acervo técnico esquecido

Padrões, arquiteturas e soluções construídas ao longo de vinte anos não alimentam a IA que as equipes usam hoje.

Nenhuma visibilidade

A diretoria não tem hoje um painel de quanto cada equipe usa, nem de quais projetos geram mais consultas.

O QUE PROPOMOS

Um Hub de IA local, da própria empresa

Uma instância de Inteligência Artificial rodando na infraestrutura que vocês já têm — GPU de 24GB de VRAM e 64 a 128GB de RAM —, atendendo as três equipes por uma interface única, com fila organizando o acesso simultâneo.

Modelo

Qwen2.5-Coder 14B, executado via Ollama — qualidade de código próxima a modelos muito maiores.

Infraestrutura

A GPU de 24GB de VRAM e a RAM já existentes na empresa — sem compra inicial de hardware.

Atendimento

As três equipes, até 18 desenvolvedores, com fila organizando o acesso simultâneo.

"O mesmo investimento que hoje paga uma licença por pessoa passa a sustentar as três equipes ao mesmo tempo — e o código continua dentro de casa."

COMO ENTREGAMOS ISSO

Um núcleo já validado, com caminho claro de evolução

FASE 1 · AGORA

Núcleo do Hub de IA local

- IA local (Qwen 14B) atendendo as três equipes, com fila de atendimento.
- Todo o processamento dentro da rede interna da empresa.
- Acesso controlado por conta e por rede, sem depender de fornecedor externo.

FASE 2 · EVOLUÇÃO A AVALIAR

Governança e reuso de conhecimento

- Roteamento híbrido: demandas complexas e sem sigilo podem usar APIs externas de ponta; tudo que envolve dado sensível continua local.
- Cotas e métricas de uso por equipe e por projeto, visíveis à diretoria.
- Indexação do acervo técnico de 20 anos, para a IA sugerir código no padrão da própria fábrica de software.

A Fase 2 é desenhada em conjunto após o piloto da Fase 1 — não faz parte do escopo ou do investimento inicial.

PARA QUEM ATENDE BANCOS, ISSO IMPORTA MAIS QUE PREÇO

Segurança e conformidade por desenho

- Processamento e dados tratados dentro da rede interna — nenhum código enviado a servidores de terceiros.
- Acesso restrito por autenticação e rede interna; a API local, isoladamente, não exige senha.
- Contas de acesso documentadas, com procedimento formal de revogação no desligamento.
- Superfície de exposição de dados de clientes bancários e acadêmicos reduzida de forma mensurável.

Menos dados trafegando para fora da empresa significa menos superfície de risco sob a LGPD nos contratos com bancos, universidades e demais clientes que exigem confidencialidade contratual.

OS NÚMEROS POR TRÁS DA DECISÃO

Investimento, economia e retorno

CENÁRIO	CUSTO MENSAL
Situação atual (assinaturas por usuário)	R$ 10.000,00
Híbrido (local + ferramentas externas, Fase 2)	R$ 7.858,40
Somente local (Fase 1)	**R$ 3.858,40**

R$ 6.141,60

economia potencial por mês no cenário somente local (61%)

R$ 6.000

investimento de implantação — GPU já reaproveitada, custo de aquisição zero

1 a 3 meses

retorno do investimento, conforme o cenário adotado

Rigor técnico já validado — não é só uma ideia no papel

66 verificações automatizadas aprovadas, compilação e build de produção validados, 20 cenários de memória testados — antes mesmo de tocar o servidor de vocês.

Gasto atual e faturamento anual informados pela empresa. Demais valores são estimativas de planejamento, a confirmar durante o piloto.

PRÓXIMO PASSO

Uma conversa técnica de 40 minutos, sem compromisso

Antes de qualquer proposta formal, queremos entender os detalhes do seu ambiente — a GPU exata, se são 64 ou 128GB de RAM disponíveis, e como as três equipes usam IA hoje. Isso define o desenho real do piloto.

Nessa conversa, vamos:

- Confirmar hardware disponível e volume real de uso de IA hoje.
- Alinhar expectativas de segurança, LGPD e confidencialidade com clientes bancários.
- Desenhar o piloto com uma das três equipes, antes de qualquer decisão maior.

Vamos agendar essa conversa?

Equipe de Implantação de IA Local · Projeto Integrado