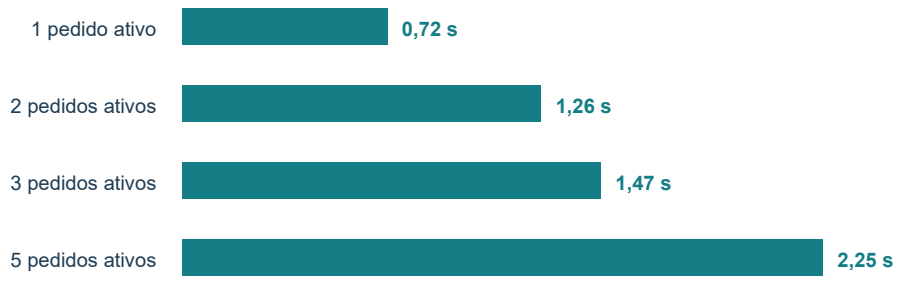
Todos os gráficos, em um arquivo

Seis gráficos anteriores + nova projeção de memória para 15 pessoas + proposta de hardware.

01 / TEMPO DE RESPOSTA PUBLICADO

Mais pedidos aumentaram o tempo de resposta

Qwen3-Coder 30B em RTX 4090 de 24 GB | Primeira resposta completa | Menor é melhor



Fonte: Jaigouk Kim, gpumod, Mixed Workload Benchmark, 22/02/2026. Ensaio independente de curta duração.

Teste externo com Qwen3-Coder 30B e pedidos de tamanhos diferentes. Mede a primeira resposta completa da tarefa principal; não mede tempo até o primeiro token. Não permite extrapolar para 15 pessoas. [1]

02 / QUALIDADE EM PROGRAMAÇÃO

Acertos em um teste publicado de programação

BigCodeBench-Instruct Full | Maior percentual significa mais problemas resolvidos



Fonte: Qwen Team, Qwen2.5-Coder Technical Report, versão 3, tabela 16. Modelos originais; não é teste Q4.

Comparação no mesmo teste, publicada pela Qwen. Resultados dos modelos originais; não são medições das versões Q4 no equipamento da empresa. [2]

O que muda para 15 pessoas: o dimensionamento adicional usa Qwen2.5-Coder 14B Q4_K_M, conforme o piloto anterior. A proposta parte de uma GPU de 48 GB para contexto de 8 mil tokens; a compra depende também de comprovar velocidade com 15 gerações ativas.

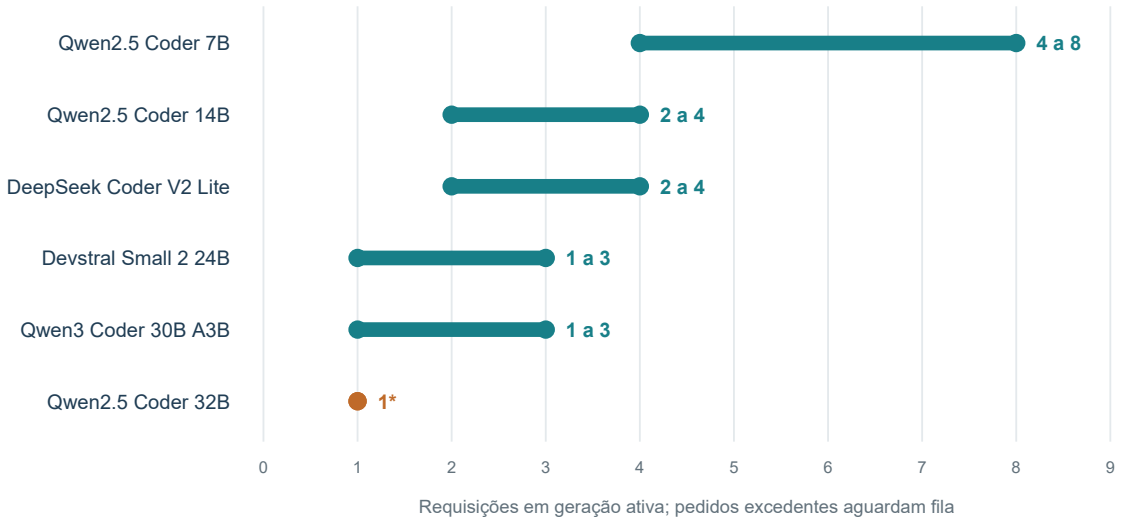
Capacidade: projeções anteriores

Gráficos preservados do estudo de 22/09. Faixas de piloto e memória estimada não são resultados medidos.

03 / FAIXAS PROPOSTAS PARA O PILOTO

Atendimentos simultâneos a testar

GPU de 24 GB e RAM de 128 GB | Hipóteses para piloto, sem benchmark no equipamento



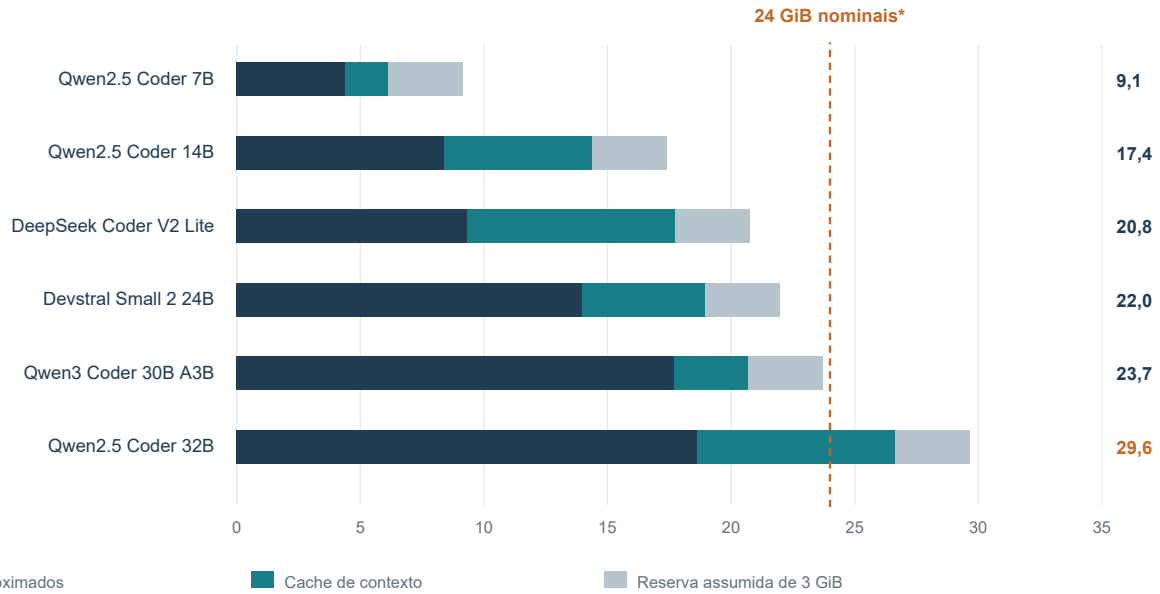
Premissas: um modelo Q4_K_M por vez, texto, contexto total de 8.192 tokens e cache f16.

* 32B próximo do limite de memória; uma sessão pode exigir contexto de 4.096 tokens. Faixas não são capacidades garantidas.

04 / MEMÓRIA COM QUATRO PEDIDOS

Memória estimada para quatro requisições

Cálculo de planejamento | Q4_K_M, 8.192 tokens por sessão e cache f16



Unidade: GiB. Fontes: pacotes Ollama e configurações dos autores; fórmula no relatório. Não mede velocidade.

DeepSeek: hipótese conservadora de cache expandido. O consumo real depende da implementação de MLA.

* Confirmar a memória reportada pelo driver. Pesos aproximados por download; buffers e picos reais podem variar.

O gráfico 04 usa reserva de 3 GiB. A nova projeção da página 4 usa 2 a 4 GiB para mostrar a sensibilidade dos buffers. Projeções originais: estudo [A].

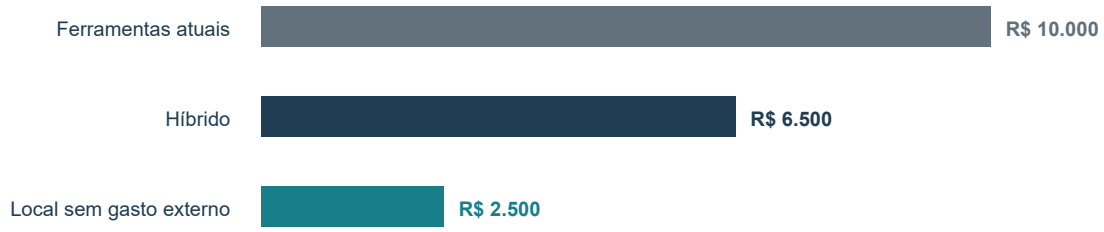
Custos: gráficos e conciliação

As duas versões ficam identificadas. Aquisição de GPU e novo servidor não estão incluídas nos cenários.

05 / PRIMEIRA SIMULAÇÃO: VALORES ARREDONDADOS

Custo mensal em cenários ilustrativos

Valores assumidos para simulação; não são orçamento nem economia comprovada

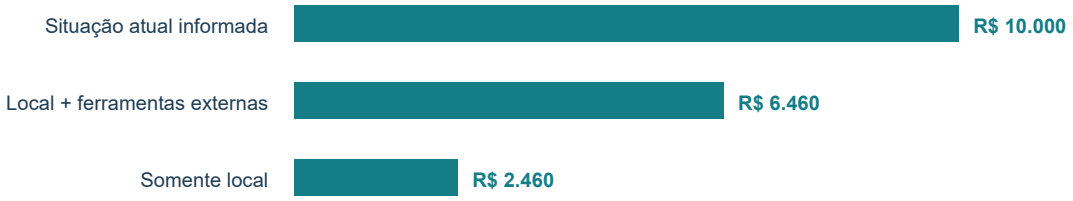


Local: R$ 2.500/mês. Híbrido: local + R$ 4.000/mês de ferramentas externas. Implantação: R$ 6.000 à parte.
A economia depende de contratos efetivamente reduzidos e produtividade preservada.
Base atual de R$ 10 mil/mês informada pelo cliente. Demais valores são hipóteses de planejamento.

06 / SIMULAÇÃO REVISADA: ENERGIA ARREDONDADA

Quanto a empresa poderia gastar por mês

Simulação de planejamento | Implantação cobrada à parte



Fonte: gasto atual informado pelo cliente e cálculo próprio com as premissas desta página. Não é cotação.

Referência de planejamento	Somente local / mês	Híbrido / mês
Gráfico 05 - primeira aproximação	R$ 2.500,00	R$ 6.500,00
Gráfico 06 - energia em R$ 160	R$ 2.460,00	R$ 6.460,00
Cálculo com centavos - documento de 24/09	**R$ 2.458,40**	**R$ 6.458,40**

Base de cálculo: suporte 12 h × R$ 150 + energia/refrigeração (0,5 kW × 220 h × R$ 1,20 × 1,2) + manutenção R$ 300 + monitoramento R$ 200. Híbrido acrescenta R$ 4.000 de ferramentas externas. Implantação ilustrativa: R$ 6.000 à parte. [A-C]

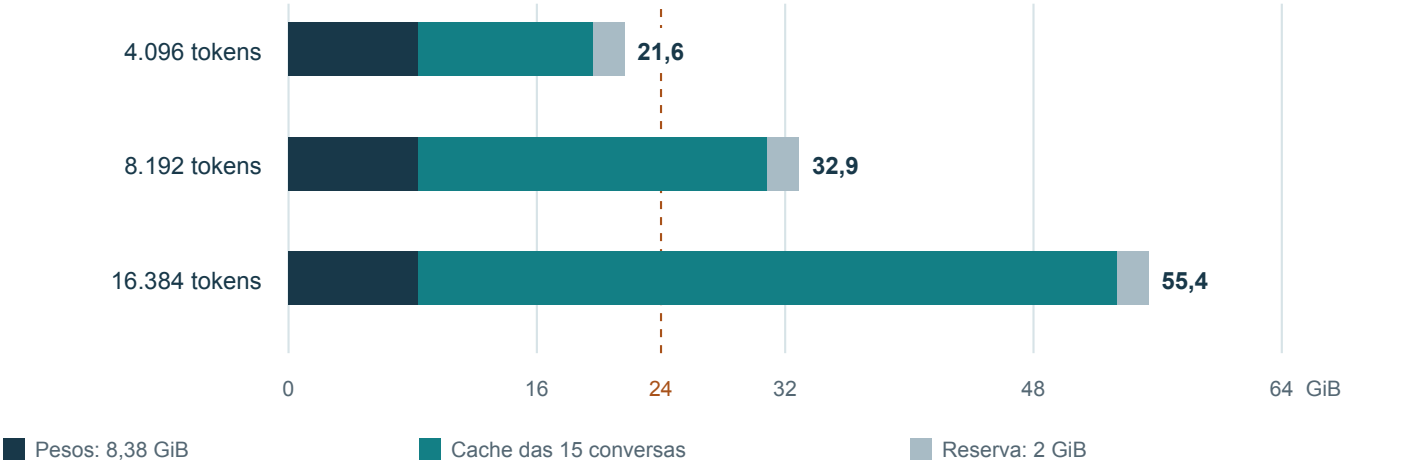
Para o upgrade: recalcular energia, suporte e investimento após cotação. Os 500 W médios da máquina antiga não representam o consumo de um servidor com GPU nova. Apenas o gasto atual de R$ 10 mil/mês veio do cliente; os demais valores são hipóteses.

15 pessoas gerando ao mesmo tempo

Qwen2.5-Coder 14B Q4_K_M | 1 pedido ativo por pessoa | cache FP16 | contexto totalmente ocupado.

Para 8.192 tokens por pessoa, projetam-se 32,9 a 34,9 GiB de VRAM. Uma GPU de 24 GiB não comporta este cenário integralmente na GPU, com essas premissas. A classe de 48 GB oferece margem de memória; não garante o tempo de resposta. [3-5]

07 / VRAM PROJETADA PARA 15 PEDIDOS ATIVOS



Contexto total por pedido	Projeção com reserva de 2 a 4 GiB	Leitura para a compra
4.096 tokens (4K)	21,6 a 23,6 GiB	24 GiB: margem estreita; testar antes de manter.
8.192 tokens (8K)	32,9 a 34,9 GiB	48 GB: proposta principal por memória.
16.384 tokens (16K)	55,4 a 57,4 GiB	64 GB: margem menor; avaliar 80/96 GB ou réplicas.

Como foi calculado: 2 (K e V) × 48 camadas × 8 cabeças KV × 128 dimensões × 2 bytes = 192 KiB por token. Pesos: 9.000.000.000 bytes / 2^30 = 8,38 GiB. Somam-se o cache dos 15 pedidos e a reserva assumida. Contexto inclui entrada, histórico e saída. [3,4]

Os 9 GB de arquivo aproximam os pesos carregados; buffers e picos dependem do executor. GB é a unidade comercial; GiB é a unidade binária do cálculo. Confirmar capacidade livre no driver. Reduzir/quantizar o cache pode diminuir memória, mas exige outro teste de qualidade e desempenho. [5]

Hardware recomendado para o piloto de 15

Proposta de dimensionamento, não requisito certificado. Modelo exato da GPU e CPU atuais ainda não informado.

Componente	Ação proposta e motivo
GPU - prioridade 1	**1 GPU de 48 GB** para Qwen 14B Q4 e 8K por pessoa. Exemplo de classe: NVIDIA RTX 6000 Ada, 48 GB e potência máxima de 300 W. Conferir preço, driver e benchmark do conjunto. [6]
Mais contexto	Para 16K, uma GPU de **80/96 GB** oferece mais margem. Exemplo: RTX PRO 6000 Blackwell Workstation, 96 GB e até 600 W. 96 GB é folga de planejamento, não mínimo obrigatório nem garantia de maior velocidade. [7]
RAM	**Manter os 128 GB** como ponto de partida se o servidor for dedicado. Não há evidência de necessidade de 256 GB para este modelo. Expandir só se medições mostrarem pressão por outros serviços, indexação ou múltiplos modelos. RAM não substitui VRAM.
CPU e armazenamento	Verificar o processador atual. Para uma máquina nova, 12-16 núcleos físicos e NVMe de 1-2 TB são especificação inicial de operação, não mínimos do modelo. CPU atende interface, tokenização e serviços; SSD guarda modelos, código e índices.
Plataforma e energia	Validar espaço físico, slots/linhas PCIe, conectores, fonte, refrigeração e nobreak conforme GPU, CPU e carga total. 300/600 W são limites da GPU, não consumo médio do servidor. Solicitar dimensionamento elétrico ao integrador. [6,7]
Rede	Rede cabeada de 1 Gb/s é ponto de partida para texto. Avaliar 2,5/10 Gb/s apenas se tráfego de arquivos, armazenamento remoto ou topologia do serviço justificar.

SE A VELOCIDADE AINDA FOR INSUFICIENTE

Duas GPUs de 48 GB com duas réplicas do modelo permitem distribuir, por exemplo, 8 pedidos para uma e 7 para a outra. É uma alternativa a medir para aumentar capacidade de processamento. Cada réplica ocupa seus próprios pesos e cache; o roteamento precisa ser configurado. [8]

Duas GPUs de 24 GB não equivalem automaticamente a uma de 48 GB. Com réplicas e 8K, a placa com 8 pedidos usaria cerca de 22,4 a 24,4 GiB nesta projeção, deixando pouca ou nenhuma margem. Dividir um modelo entre GPUs exige suporte do executor e validação do custo de comunicação. [5]

Validação e referências

A memória permite carregar a carga; o teste define se as 15 pessoas conseguem trabalhar com fluidez.

Teste de aceite proposto: rodar 15 solicitações realmente sobrepostas, com tarefas e saídas representativas; registrar tokens de entrada/saída, tempo até o primeiro token (p50/p95), tokens por segundo por usuário, fila, erros e picos de VRAM. Repetir com contexto até o limite escolhido e separar carga inicial de modelo já carregado.

Exemplo de meta a negociar: 15 tokens/s de saída por pessoa exige pelo menos **225 tokens/s agregados** enquanto as 15 gerações estão ativas. Isso é uma meta de teste, não desempenho prometido de uma placa. Um agente que abre vários pedidos por usuário pode exigir mais que 15 vagas.

Configurar paralelismo, contexto e fila no executor; considerar processamento em lotes contínuos quando suportado. Aumentar apenas o número de conexões não comprova 15 gerações paralelas. GGUF no vLLM é experimental; trocar formato ou precisão exige redimensionar a memória. [5,8,9]

FONTES TÉCNICAS E ESPECIFICAÇÕES

[1] Autor do gpumod. Mixed Workload, 22/02/2026. Ensaio independente, fonte do gráfico 01.

[2] Qwen. Qwen2.5-Coder Technical Report, v3, tabela 16. Resultados do gráfico 02.

[3] Qwen. Configuração do 14B: camadas, cabeças KV e dimensões.

[4] Qwen. GGUF Q4_K_M oficial: arquivo de aproximadamente 9 GB.

[5] Ollama. FAQ: concorrência, contexto, cache, múltiplas GPUs e filas.

[6] NVIDIA. RTX 6000 Ada: especificações de memória e potência.

[7] NVIDIA. RTX PRO 6000 Blackwell Workstation: memória e potência.

[8] vLLM. Data Parallel Deployment: réplicas para distribuir requisições.

[9] vLLM. GGUF: suporte experimental e limitações de otimização.

ARQUIVOS DE ORIGEM E LIMITES

[A] Estudo IA local 128 GB / 24 GB, de 22/09: gráficos 03, 04 e 05, com suas hipóteses originais.
[B] Relatórios objetivos IA local, de 22/09: gráficos 01, 02 e 06.
[C] Custos e instalação da solução LLM, de 24/09: total mensal com centavos.

Fontes técnicas para a nova recomendação consultadas em 28/09/2026. Os gráficos antigos foram preservados e identificados; a projeção 07 é cálculo novo. Não foram executados testes na máquina da empresa. Cotação, inventário do equipamento e teste de carga ainda são necessários para fechar a compra.