IA Local para Desenvolvimento

Substituindo assinaturas de IA por usuário por uma solução própria, segura e sob controle da empresa.

Projeto Integrado · Atividade 2 — Custos e instalação da LLM · 05/10/2026

O ponto de partida

Hoje a equipe de desenvolvimento usa ferramentas de IA por assinatura — uma licença por pessoa.

R$ 10.000 por mês

Esse valor equivale a cerca de 1% do faturamento mensal — não é uma ameaça ao caixa, mas uma oportunidade real de otimização a ser investigada.

Fonte: gasto atual informado pela empresa

Por que repensar o modelo por usuário

Custo que escala com a equipe

Cada nova contratação significa uma nova licença — o gasto não tem teto.

Dados saem da empresa

Código, prompts e informações internas trafegam para servidores de terceiros a cada consulta.

Dependência do fornecedor

Preço, disponibilidade e recursos ficam fora do controle da empresa.

Sem adaptação ao time

A ferramenta não foi pensada para o fluxo de trabalho específico da equipe.

IA local, sob controle da empresa

Modelo Qwen2.5-Coder 14B executado localmente via Ollama, usando a infraestrutura já existente. Atende explicação de código, correções e criação de testes automatizados.

Modelo

Qwen2.5-Coder 14B, quantização Q4_K_M

Infraestrutura

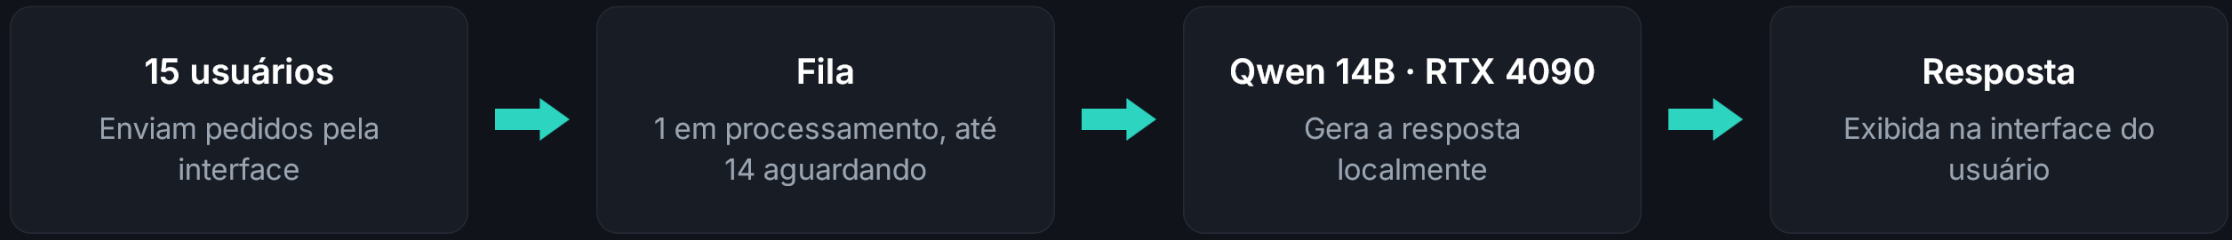
RTX 4090 de 24 GB + 128 GB de RAM já existentes na empresa

Atendimento

15 desenvolvedores, com fila organizando o acesso

Fonte: proposta técnica de implantação, 29/09/2026

Como funciona o atendimento



Cada pessoa mantém uma solicitação aberta por vez, com estados: Na fila → Em processamento → Concluído.

Qualidade comparável aos modelos maiores

Percentual de acertos em um teste público de programação. O modelo escolhido, 14B, fica muito próximo do 32B, bem maior.



Resultados dos modelos originais, não da versão Q4 usada no projeto · Fonte: Qwen2.5-Coder Technical Report, tabela 16

Comparativo de custos e retorno

Cenário	Custo mensal
Situação atual (assinaturas por usuário)	R$ 10.000,00
Híbrido (local + ferramentas externas)	R$ 7.858,40
Somente local	R$ 3.858,40

R$ 6.141,60

economia potencial por mês no cenário totalmente local (61%)

~2,8 meses

payback do investimento de implantação (R$ 6.000), validado pelo simulador no cenário híbrido

Fonte: proposta técnica de 29/09/2026 e validação do simulador em 05/10/2026

Segurança e controle dos dados

- Processamento e armazenamento dentro da rede interna da empresa — nenhum código enviado a terceiros.
- Acesso restrito por chave SSH e rede interna; a API local, sozinha, não exige senha.
- Contas de acesso documentadas, com procedimento de revogação no desligamento de funcionários.
- Backup do ambiente e teste de restauração realizados antes da entrega do servidor.

Fonte: plano de preparação e entrega do servidor de IA

Rigor técnico já validado

O simulador de custos e capacidade foi testado em 05/10/2026, antes mesmo da instalação no servidor.

66
verificações automatizadas aprovadas

20
cenários de memória testados

PASS
compilação TypeScript e build de produção

Git limpo
nenhuma alteração indevida de código durante os testes

Fonte: registro de evidências, 05/10/2026 · commit 8303cbe

Crescer com o uso, não com mais licenças

Hoje

RTX 4090 de 24 GB atende 1 geração ativa por vez (cerca de 12,9 GiB de VRAM), com fila para os outros 14 usuários.

Se a demanda pedir mais

Uma GPU de 48 GB comporta as 15 gerações simultâneas em contexto de 8 mil tokens (cerca de 32,9 a 34,9 GiB).

A expansão é um investimento pontual em hardware — não uma nova assinatura por pessoa contratada.

Fonte: estudo de gráficos e hardware para 15 pessoas, 28/09/2026

Próximos passos

1. Conferir servidor — sistema, GPU, memória, armazenamento e rede.
2. Instalar o Ollama e baixar o modelo Qwen2.5-Coder 14B.
3. Proteger o acesso com autenticação e restrição de rede.
4. Integrar a aplicação — chat, fila e estados de atendimento.
5. Testar e validar — qualidade, espera, consumo e recuperação.

Aprovação solicitada: iniciar o piloto com os 15 usuários reais e medir o desempenho antes da decisão de expansão.