ENTREGA DOCUMENTADA

José — Evidências da entrega: custos e instalação da LLM

Levantamento de custos e procedimentos de instalação concluído e documentado.

Escopo da atividade 2. Levantamento dos custos e dos procedimentos necessários para instalação e utilização da solução na LLM. Os documentos abaixo comprovam a entrega técnica e financeira dessa responsabilidade.

Matriz de evidências

Entrega verificada	Onde está a evidência	Achado concreto
Custos e investimento	**[A] p. 3** [C] Composição dos custos e Simulação financeira	Operação local de R$ 3.858,40/mês; híbrida de R$ 7.858,40/mês. Base inicial de R$ 6.000, mais orçamento da fila.
Procedimentos de instalação	**[C] Procedimentos de instalação e disponibilização**, etapas 1 a 7	Conferência do equipamento, Ollama, download do modelo, configuração, acesso restrito, integração e validação.
Modelo e utilização	**[A] pp. 1-2** [C] Fundamentos da escolha	Qwen2.5-Coder 14B Q4_K_M; usos em explicação de código, correções e testes. Justificativa por qualidade e tamanho.
Acesso e fila	**[A] p. 1** Fluxo e regras da operação	15 usuários; uma geração inicial; até 14 pedidos aguardando. Contexto de 8.192 tokens e uma solicitação aberta por usuário.
Dimensionamento	**[B] p. 4** [A] p. 2	Fórmula de cache e cenários de VRAM. Cerca de 12,9 GiB para uma geração; 32,9-34,9 GiB para 15 em 8K.
Expansão e avaliação	**[B] pp. 5-6** [C] Critérios para avaliar a adoção	Alternativas de hardware e critérios de qualidade, latência, memória, energia e produtividade documentados.
Referências rastreáveis	**[B] p. 6** [C] Referências	9 referências no consolidado e 13 no DOCX: modelo, instalação, acesso, hardware, medição e tarifa.

Identificação dos anexos: [A] Proposta Qwen14B com fila, 29/09/2026, 3 páginas. [B] Gráficos e hardware para 15 pessoas, 28/09/2026, 6 páginas. [C] Custos e instalação da solução LLM, DOCX de 24/09/2026. Nomes completos na página 3.

CONFERÊNCIA DAS CONTAS

Custos revisados e memória

A proposta com fila de **29/09/2026** é a referência financeira vigente. Os cálculos abaixo reproduzem suas premissas e os cenários técnicos dos anexos.

Componente	Base de cálculo	Valor
Suporte mensal	Valor revisado da proposta	R$ 3.000,00
Energia do computador	0,5 kW × 220 h × R$ 1,20/kWh	R$ 132,00
Refrigeração	20% × R$ 132,00	R$ 26,40
Reserva de manutenção	Valor revisado da proposta	R$ 500,00
Monitoramento	Provisão mensal	R$ 200,00
Total local mensal	**Soma dos cinco componentes**	**R$ 3.858,40**
Ferramentas externas	Opcional, no cenário híbrido	R$ 4.000,00
Total híbrido mensal	**Local + ferramentas externas**	**R$ 7.858,40**

Implantação base: 40 h × R$ 150/h = **R$ 6.000**. Compra inicial de GPU: **R$ 0**, pelo reaproveitamento previsto. Fila, painel de status e integração adicional: orçamento próprio. Fonte: [A], p. 3.

Memória: cálculo reproduzível

Cache por token: **2 × 48 camadas × 8 cabeças KV × 128 dimensões × 2 bytes = 192 KiB**. Pesos aproximados: 9.000.000.000 bytes ÷ 2^{30} = **8,38 GiB**. A soma inclui pesos, cache de cada pedido e reserva do executor. [B], p. 4.

Cenário	Cache total	VRAM estimada
1 geração · 8.192 tokens · reserva 3 GiB	1,50 GiB	**12,9 GiB**
15 gerações · 4.096 tokens · reserva 2-4 GiB	11,25 GiB	21,6-23,6 GiB
15 gerações · 8.192 tokens · reserva 2-4 GiB	22,50 GiB	**32,9-34,9 GiB**
15 gerações · 16.384 tokens · reserva 2-4 GiB	45,00 GiB	55,4-57,4 GiB

O primeiro cenário reproduz a proposta com fila [A], p. 2. Os demais reproduzem [B], p. 4. Os 128 GB de RAM não se somam à VRAM. Memória suficiente não determina a velocidade de geração.

VALIDAÇÃO E RASTREABILIDADE

Verificações do simulador

Registro da verificação: 05/10/2026, às 13:42 (BRT). Projeto: **output/dashboard-ia-local**. O conjunto passou **66 asserções** e verificou a compilação e a coerência dos cálculos do simulador.

Verificação	Resultado registrado
TypeScript	**PASS** · npx tsc --noEmit --incremental false Código de saída 0.
Build de produção	**PASS** · npm run build Código de saída 0.
memory() real	**PASS** · 20 cenários: pedidos 0, 1, 5, 10 e 15 × contextos de 4.096, 8.192, 16.384 e 32.768 tokens.
costs() real	**PASS** · cenários histórico, revisado e zero. Revisado: support = 20 h, rate = R$ 150/h e maintenance = R$ 500; demais premissas preservadas.
Integridade do projeto	**Git limpo antes e depois** das verificações. Testes sem alteração dos arquivos do dashboard.

Os resultados validam o simulador e os cálculos. Não constituem benchmark da LLM no servidor da empresa.

Versão verificada

Commit: 8303cbeb1b3018ddf9e379f63b270aa7ee44ca47

SHA-256 de lib/analysis.ts:
7288b53481e72712526b9220d421de4cfad41d3015fc35f999dc8b63c10b7664

Documentos de origem

[A] Proposta_IA_local_Qwen14B_com_fila.pdf · 29/09/2026.
[B] IA_local_graficos_e_hardware_15_pessoas.pdf · 28/09/2026.
[C] Custos_e_instalacao_da_solucao_LLM.docx · 24/09/2026.

Controle de versão financeira. O DOCX, os gráficos anteriores e os valores padrão do dashboard preservam as premissas históricas. Para o orçamento atual, prevalece [A]: suporte de R$ 3.000 e manutenção de R$ 500. O cenário revisado do teste aplica esses valores sem modificar o simulador.

Alcance da entrega

O levantamento e a documentação da atividade de José estão concluídos. Os custos permanecem valores de planejamento. Execução no servidor, medições reais e contratação da implantação pertencem à etapa operacional do projeto.