Qwen2.5-Coder 14B com fila de atendimento

Opção recomendada para esta proposta: IA local na RTX 4090 de 24 GB, com os 128 GB de RAM existentes.

15 usuários com acesso. Máquina atual preservada. Compra de GPU fora da implantação inicial.

Fluxo de uso proposto

15 usuários

Enviam solicitações pela interface da equipe.

→

Fila antes da API

Guarda os pedidos e libera um por vez, por ordem de chegada.

→

API da IA local

Recebe o pedido liberado. O Qwen 14B gera a resposta na RTX 4090.

→

Resposta ao usuário

A interface exibe o resultado. Ao concluir, o serviço libera o próximo pedido da fila.

Se 15 pedidos chegarem juntos: 1 em processamento e até 14 aguardando na fila.

Como a equipe usará

Explicação de código, correções e criação de testes automatizados. Cada pessoa acompanha os estados **Na fila**, **Em processamento** e **Concluído**, com opção de cancelar enquanto aguarda.

O tempo total inclui a espera na fila e a geração da resposta. Picos de demanda aumentam a espera.

Regras da operação

1 solicitação aberta por usuário. A aplicação controla o acesso e a posição na fila. O limite de processamento será configurável, começando com uma resposta por vez.

Até 8.192 tokens por conversa, contando pergunta, histórico e resposta. Tokens são pequenos trechos de texto. Haverá prazo máximo e aviso de falha ou indisponibilidade.

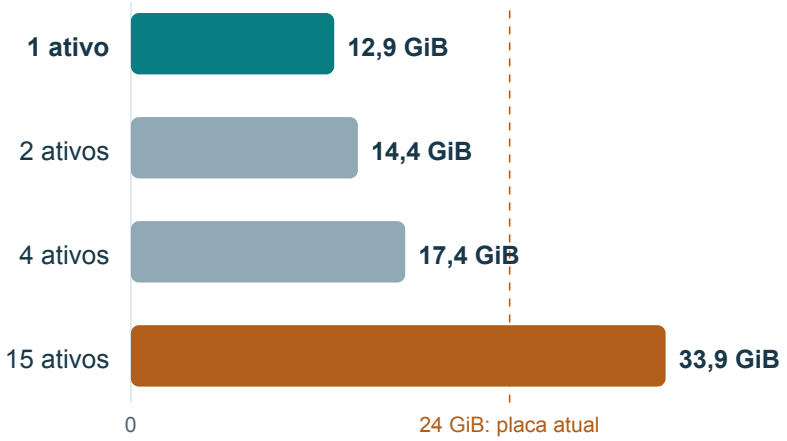
Fonte: fluxo desenhado para esta proposta. O controle de fila e usuários pertence à aplicação. Referências: Ollama: concorrência e filas e autenticação da API local.

Uso da máquina e possibilidade de melhoria

A fila organiza o acesso de 15 pessoas e limita quantos pedidos chegam à IA ao mesmo tempo.

Memória da RTX 4090

Estimativa por quantidade de pedidos em processamento.

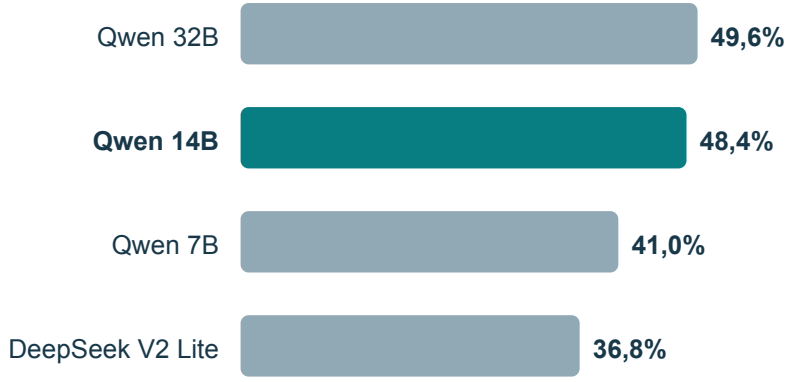


Configuração proposta: 1 ativo, cerca de 12,9 GiB. Os pedidos aguardando ficam na aplicação, antes da API.

Fonte: cálculo próprio com Qwen: arquitetura, arquivo Q4, Ollama e NVIDIA.
8.192 tokens, cache FP16 e reserva de 3 GiB. GiB é a unidade do cálculo. Memória estimada, sem previsão de velocidade.

Qwen 14B: escolha desta proposta

Acertos em um teste de programação. Maior é melhor.



Escolha pelo equilíbrio entre qualidade e tamanho. O 14B ficou próximo do 32B nessa avaliação.

Fonte: Qwen, relatório técnico, 2024, tabela 16.
BigCodeBench-Instruct Full, modelos originais. A versão compacta Q4 pode ter resultado diferente. Qwen = Qwen2.5-Coder.

Melhoria de hardware somente quando a demanda justificar

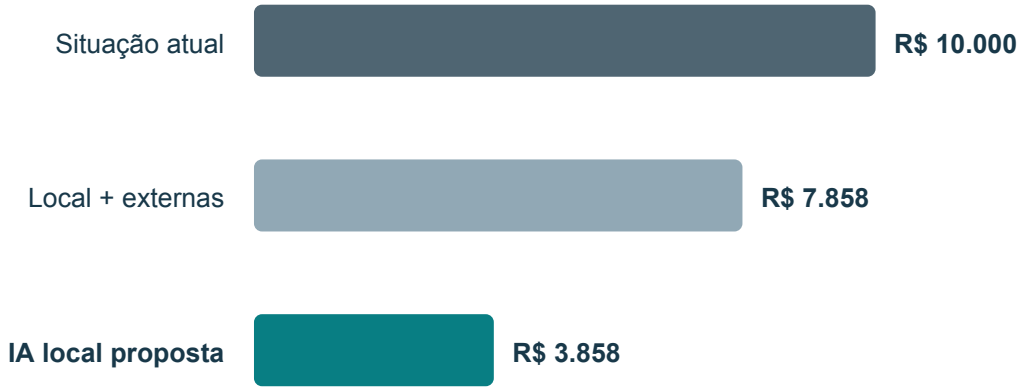
Se a espera recorrente prejudicar o trabalho, ampliar o processamento dentro da capacidade da RTX 4090. Caso a demanda continue acima da capacidade, orçar uma GPU com mais memória ou outro servidor. A expansão terá orçamento próprio.

Custos da implantação e do uso

Proposta principal: Qwen 14B com fila na máquina existente. Ferramentas externas permanecem opcionais.

Custo mensal de referência

Valores arredondados. Cenário local em destaque.



Operação local: R$ 3.858,40/mês estimados. Manter R$ 4.000 de ferramentas externas elevaria o cenário para R$ 7.858,40/mês.

A fila compartilha a máquina atual. Não exige compra inicial de GPU.

Fonte: gasto atual informado pela empresa e cálculo próprio.
Base: “Custos e instalação da solução LLM”, 24/09/2026, p. 2. Suporte e reserva atualizados pelo cliente em 29/09/2026.
Valores de planejamento.
Fila a orçar. Reduzir despesas externas depende dos contratos encerrados.

Uso mensal previsto

Suporte	**R$ 3.000**
Energia e refrigeração	**R$ 158**
Reserva de manutenção	**R$ 500**
Monitoramento	**R$ 200**

Suporte e reserva: valores mensais definidos para a proposta. Energia estimada: 500 W médios, 220 h/mês, R$ 1,20/kWh e 20% de refrigeração. O consumo pode mudar com o uso.

Investimento inicial

Compra de GPU	**R$ 0**
Implantação base	**R$ 6.000**
Fila e integração à API	**A orçar**

Base: 40 h × R$ 150. A fila, o painel de status e os controles são escopo adicional. **Total inicial: R$ 6.000 + orçamento da fila.**