Visão do Produto — Hub de IA Local

Descrição da solução inicial proposta

---

1. Declaração de visão

Para as equipes de desenvolvimento de uma fábrica de software que precisa reduzir custos com ferramentas de IA e proteger o código de clientes sensíveis (bancos, universidades), o **Hub de IA Local** é uma solução interna de Inteligência Artificial, administrada pela própria empresa, que oferece explicação de código, correção de erros e sugestões de desenvolvimento pela infraestrutura já existente. Diferente das ferramentas de IA por assinatura usadas atualmente, o Hub de IA Local processa tudo dentro da rede da empresa, sem depender de um fornecedor externo nem gerar um custo crescente por usuário.

---

2. Problema que motiva o produto

As três equipes de desenvolvimento usam, há cerca de um ano, ferramentas de IA por assinatura para ganhar produtividade. Esse uso já representa um custo mensal relevante e traz três problemas de fundo:

- **Custo sem teto** — o gasto cresce junto com o uso, sem controle por equipe ou projeto.
- **Exposição de dados** — código e prompts de clientes com exigência de confidencialidade (bancos, universidade) saem da rede da empresa a cada consulta.
- **Dependência externa** — preço, disponibilidade e recursos da ferramenta não estão sob controle da empresa.

3. Público-alvo e stakeholders

Papel	Quem	Interesse
Usuários diretos	Desenvolvedores das 3 equipes (15–18 pessoas)	Tirar dúvidas, explicar e corrigir código no dia a dia
Patrocinador / decisor	Diretoria da fábrica de software	Controle de custo e redução de risco
Stakeholders indiretos	Clientes finais (bancos, universidade, empresa de acervo, agência de viagens)	Confidencialidade do código entregue

4. Solução inicial proposta (MVP)

Um protótipo de IA local, administrado pela empresa, com foco inicial restrito e deliberadamente simples:

- **Modelo:** Qwen2.5-Coder 14B, quantização Q4_K_M, executado via Ollama.
- **Infraestrutura:** a GPU de 24GB de VRAM e a RAM (64–128GB) já existentes — sem

compra inicial de hardware.

- **Interface:** chat interno onde qualquer desenvolvedor das três equipes envia perguntas sobre programação, pede explicações de código ou sugestões de correção.
- **Fila de atendimento:** organiza o acesso simultâneo — uma solicitação em processamento por vez, as demais aguardando, com estados visíveis (Na fila → Em processamento → Concluído).
- **Rede:** acesso restrito à rede interna da empresa; nenhuma informação trafega para fora.

A substituição completa das ferramentas atuais **não** é uma promessa deste MVP — o objetivo é validar se a infraestrutura existente sustenta uma IA própria com qualidade e custo adequados.

5. Principais funcionalidades do MVP

- Perguntas e respostas sobre programação em linguagem natural.
- Explicação de trechos de código existentes.
- Sugestão de correções para erros apontados pelo desenvolvedor.
- Fila com posição visível e opção de cancelamento enquanto aguarda.
- Painel simples de estado do pedido (Na fila / Em processamento / Concluído).

6. Diferenciais em relação à alternativa atual

- **Custo previsível:** um investimento de infraestrutura compartilhado pelas três equipes, em vez de uma licença por pessoa que escala com a contratação.
- **Dado dentro de casa:** nenhum código ou prompt sai da rede interna, reduzindo a superfície de risco em contratos que exigem confidencialidade.
- **Independência de fornecedor:** preço, disponibilidade e roadmap deixam de depender de terceiros.

7. Fora do escopo inicial (evolução futura)

Para manter o MVP viável, os itens abaixo ficam fora desta primeira entrega e só são avaliados depois do piloto:

- Roteamento híbrido (parte local, parte via APIs externas de ponta para demandas sem sigilo).
- Cotas e métricas de uso por equipe/projeto em um painel para a diretoria.
- Indexação do acervo técnico de 20 anos da empresa (RAG) para sugestão de código no padrão da fábrica de software.

8. Critérios de sucesso do protótipo

Critério	Pergunta que o protótipo precisa responder
Qualidade	As respostas ajudam a resolver as tarefas de programação testadas?
Desempenho	Qual o tempo de resposta e como ele muda com várias pessoas usando ao mesmo tempo?
Capacidade	Quantos usuários simultâneos a configuração testada atende de forma aceitável?
Custo total	Quanto custa operar a solução, considerando energia, manutenção, administração e eventuais ferramentas externas mantidas?
Adequação ao trabalho	O protótipo atende às atividades prioritárias das equipes ou deixa de fora funcionalidades importantes das ferramentas atuais?
Segurança	Quem pode acessar o sistema, o que fica armazenado e como são tratados os dados enviados pelos usuários?

A conclusão do piloto pode apontar substituição parcial, uso combinado de ferramentas internas e externas, ou mesmo a inviabilidade da configuração testada — o compromisso é avaliar com critérios claros, não garantir uma economia ainda não demonstrada.